

项目2：表格基础大模型

研究背景

表格基础大模型属于预训练模型，依托上下文学习技术在结构化表格数据上完成分类与回归任务，无需针对特定数据集微调训练，即可实现效果优异的零样本预测。该方向由TabPFN率先落地，后续又衍生出TabICL、TabDPT等改进模型，正快速动摇梯度提升树长期以来在各类实测表格基准数据集上的统治地位。

硬件资源说明

表格基础大模型是本课程中算力需求较低的模型选型。TabPFN第二代与TabICL可通过pip一键安装，普通笔记本的CPU或小型独显即可运行；OpenML、TALENT平台提供的基准数据集体量适中、易于获取。**算力资源有限的同学优先推荐选择本课题。**

项目目标

(a)

选取至少两款业界前沿表格基础大模型（如TabPFN v2、TabICL、TabDPT），在TALENT、TabArena等基准数据集套件上开展实验；从预测准确率、推理速度、不同数据规模下的扩展性三个维度完成模型评测。

(b)

设计对照实验，剖析现有各类模型的优缺点，评测维度包含：模型在小体量/大体量数据集上的表现、类别型特征处理能力、缺失值鲁棒性，同时对比XGBoost、LightGBM等梯度提升基准模型的算力开销。

(c)（加分拓展项）

提出模型优化新思路，可选方向：面向特定行业下游任务微调表格基础模型、基于检索样例优化上下文学习方案、拓展模型适用场景至回归分析与生存分析任务。